



PT ARUNIKA DATA NUSANTARA

Gedung Arunika Lt. 7, Jl. Contoh Raya No. 17, Jakarta Selatan 12950
Telp (021) 555-0170 · sekretariat@arunika.example · www.arunika.example

LAPORAN INSIDEN LAYANAN TI

Nomor: INS/TI/2026/10/0004

P2

P2 · Tinggi — target pemulihan 4 jam

Dampak Sedang × urgensi Tinggi · status: Pulih

Judul insiden	: Latensi asisten LLM internal naik 3 kali lipat
Layanan terdampak	: Asisten back-office (server LLM Qwen3.5-4B, GPU T4)
Mulai terjadi	: 9 Oktober 2026 08:40 WIB
Terdeteksi	: 9 Oktober 2026 09:05 WIB
Pulih	: 9 Oktober 2026 10:20 WIB
Durasi gangguan	: 1 jam 40 menit
Pelapor	: Bayu Saputra

RINGKASAN

Waktu jawab asisten naik dari sekitar 10 detik menjadi 30–60 detik. Penyebabnya GPU server di-throttle oleh batas daya sehingga clock turun ke sekitar 400 MHz. Layanan pulih setelah dipindah ke host GPU lain.

DAMPAK TERHADAP PENGGUNA

Sekitar 60 pengguna unit pengadaan dan sekretariat menunggu 30–60 detik per jawaban; tidak ada data yang hilang.

LINIMASA

Waktu	Kejadian
08:40 WIB	Latensi p50 mulai naik di dasbor.
09:05 WIB	Keluhan pertama dari unit pengadaan; insiden dibuka.
09:30 WIB	nvidia-smi menunjukkan clock SM 360–435 MHz, alasan throttle SW power cap.
10:20 WIB	Layanan dipindah ke host GPU baru; latensi kembali normal.

AKAR MASALAH

Host GPU membatasi daya kartu di 70 W pada suhu 76 °C sehingga clock turun ke sekitar 25% dari maksimum. Tidak ada perubahan kode atau konfigurasi.

TINDAKAN PEMULIHAN

Server LLM dipindah ke host GPU lain dan cache model dihangatkan ulang; latensi diverifikasi kembali ke sekitar 10 detik.

TINDAK LANJUT PENCEGAHAN

No	Tugas	PIC	Tenggat
1	Tambahkan alarm clock SM dan alasan throttle GPU ke dasbor	Dimas Prasetyo	16 Oktober 2026
2	Tulis runbook pindah host GPU	Rina Kartika	20 Oktober 2026

Jakarta, 9 Oktober 2026

Pelapor,

Mengetahui,

Kepala Divisi Teknologi Informasi

Bayu Saputra